



UNIVERSIDAD
DE LA FRONTERA



STEAM GAMES

Integrantes: Carlos Cienfuegos, Cristopher Gallegos, Eduardo Krause, Ignacio Manríquez

¿Será un juego exitoso en base a sus tags?

Ingeniería de Datos • 2026

05-06-2026



Descripción del Dataset

22.531

Registros
(juegos)

21

Variables
originales

154

Variables
final

134

Tags
binarios

Información general

Fuente: Kaggle – Steam Games Dataset

Licencia: Uso académico / público

Tipo variables: Numéricas, categóricas, texto

Variable objetivo: Exitoso ($\text{ReviewScore} \geq 7$)

Tarea: Clasificación binaria

¿Por qué este dataset?

- ✓ 22k+ registros: suficiente para modelar
- ✓ Tags estructurados: features listas
- ✓ Pregunta clara y acotada
- ✓ Relevante para industria de videojuegos

? Definición del Problema

¿Será un juego exitoso en base a sus tags?

Tipo de tarea

Clasificación binaria
Exitoso / No exitoso

Hipótesis

Los tags de un juego
contienen señal predictiva
sobre su éxito

Criterio de éxito


Accuracy > 70%
y F1-score equilibrado
por clase




Usuarios potenciales: desarrolladores indie, publishers, plataformas de distribución digital

EDA – Visión General

Distribución ReviewScore



Lanzamientos por Año




▶ Score 7–9 concentra el 65% de juegos

▶ Crecimiento exponencial desde 2013

▶ Top tags: singleplayer, indie, action


EDA – Outliers y Distribuciones Clave

Distribución Precio



Eje X: rango de precio Eje Y: Nº de juegos

Ratio Positivo por Clase



Eje X: % reseñas positivas Eje Y: Nº de juegos

Outliers Precio

~700 juegos

sobre \$27 (fence IQR)

Outliers Reseñas

~800 juegos

juegos masivos (log)

Sin reseñas

2.879 juegos

ReviewScore = 0




Tags vs Éxito

● Tags que favorecen el éxito



● Tags que reducen el éxito





Preparación del Dataset



Acción	Detalle	Justificación
Filtrar type=game	DLC, music, mod descartados	Objetivo: solo juegos
Eliminar dups.	111 filas idénticas por AppID	Evitar sesgo
Descartar cols.	Thumbnail, Description, Genres...	No aportan al modelo
Imputar nulos	Mediana en MemReq; 'Unknown' en devs	Mantener registros
One-Hot tags	134 columnas binarias tag_*	Feature engineering

Calidad del Dataset y Próximos Pasos

22.531

juegos finales

68.8%

Exitosos (1)

31.2%

No exitosos (0)

0

nulos remanentes



Observaciones de calidad

- ! Desbalance moderado (2.2:1) → pesos de clase
- ! 13% sin reseñas → etiqueta incierta
- ! Precio y reseñas: muy asimétricos (log1p)
- ! CPU_tier sin correlación clara con éxito



Próximos pasos (Parte 2)

- Modelado: Random Forest / XGBoost
- Manejo desbalance: class_weight
- Considerar excluir score = 0
- Validación cruzada + métricas F1



Dataset validado

Problema definido • Datos preparados • Listos para la Etapa 2

¿Preguntas?